

Рубежный контроль № 1

Вариант 16 | Группа ИУ5-61Б | Нагдасёв Дмитрий

Задача 2 | Набор данных: Boston Housing Dataset

Задачи:

1. Обработка пропусков для категориального и количественного признаков
2. Выбор признаков для построения моделей машинного обучения
3. Диаграмма рассеяния для пары признаков

1. Загрузка данных и первичный анализ

Датасет **Boston Housing** содержит **506 объектов** и **14 признаков**. Загрузка и первичная инспекция выполняются следующим кодом:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')
df = pd.read_csv('HousingData.csv')
print('Форма датасета:', df.shape) # (506, 14)
df.head()
```

Пропуски присутствуют в столбцах: CRIM, ZN, INDUS, CHAS, AGE, LSTAT — по **20 значений** в каждом (~4%).

```
missing_df = pd.DataFrame({
    'Пропусков': df.isnull().sum(),
    'Доля (%)': (df.isnull().mean() * 100).round(2)
})
print(missing_df[missing_df['Пропусков'] > 0])
```

2. Создание категориального признака

Датасет содержит только числовые признаки. Создаём категориальный признак PRICE_CATEGORY на основе целевой переменной MEDV (медианная стоимость дома, тыс. \$):

Low — MEDV < 17 **Medium** — 17 ≤ MEDV < 25 **High** — MEDV ≥ 25

```
def categorize_price(val):
    if pd.isnull(val): return np.nan
    elif val < 17: return 'Low'
    elif val < 25: return 'Medium'
    else: return 'High'
df['PRICE_CATEGORY'] = df['MEDV'].apply(categorize_price)
# Искусственно вводим 10% пропусков
np.random.seed(42)
idx = np.random.choice(df.index, size=int(0.10 * len(df)), replace=False)
df.loc[idx, 'PRICE_CATEGORY'] = np.nan
```

→ 50 пропущенных значений

3. Обработка пропусков

3.1 Количественный признак: LSTAT

LSTAT — доля населения с низким социальным статусом (%). Выбранный метод: **заполнение медианой**.

Метод: медиана

Медиана устойчива к выбросам (в отличие от среднего). Распределение LSTAT правостороннее ($\text{skew} > 0$), поэтому среднее было бы смещено в сторону высоких значений. Медиана лучше отражает типичное значение признака.

```
lstat_median = df['LSTAT'].median() # 11.43
df['LSTAT'] = df['LSTAT'].fillna(lstat_median)
print(f'Пропуски после обработки: {df["LSTAT"].isnull().sum()}') # 0
```

Количественный признак LSTAT (после заполнения медианой)




Рис. 1. Гистограмма и box-plot LSTAT после заполнения медианой.

3.2 Категориальный признак: PRICE_CATEGORY

Выбранный метод: **заполнение модой** (наиболее часто встречающаяся категория).

Метод: мода

Для номинальных категориальных данных нельзя вычислить среднее или медиану. Мода — единственная корректная "центральная" характеристика. Она сохраняет наиболее распространённую категорию и минимально искажает соотношение классов.

```
price_mode = df['PRICE_CATEGORY'].mode()[0] # 'Medium'
df['PRICE_CATEGORY'] = df['PRICE_CATEGORY'].fillna(price_mode)
print(df['PRICE_CATEGORY'].value_counts())
```




Рис. 2. Распределение PRICE_CATEGORY после заполнения модой.

Итоговая таблица методов обработки пропусков

Тип	Признак	Метод	Обоснование
Количественный	LSTAT	Медиана	Правостороннее распределение (skew > 0); медиана устойчива к выбросам
Категориальный	PRICE_CATEGORY	Мода	Единственная корректная центральная характеристика для номинальных данных

4. Выбор признаков для построения моделей МО

Отбор признаков выполняется на основе коэффициента корреляции Пирсона с целевой переменной MEDV. Признаки с $|r| > 0.35$ рассматриваются как информативные.




Рис. 3. Корреляция признаков с целевой переменной MEDV.

Признак	Описание	r с MEDV	Обоснование включения
RM	Среднее кол-во комнат	+0.70	Сильнейший положительный предиктор
LSTAT	Доля низкосocioального населения	-0.74	Сильнейший отрицательный предиктор
PTRATIO	Соотношение учеников/учителей	-0.51	Качество образования в районе
INDUS	Доля нежилой территории	-0.48	Промышленная нагрузка на район
TAX	Ставка налога на имущество	-0.47	Финансовая нагрузка на жильцов
NOX	Концентрация оксидов азота	-0.43	Экологический фактор (промзоны)
CRIM	Уровень преступности	-0.39	Важный социальный фактор безопасности
AGE	Доля старых домов	-0.38	Характеризует возраст жилого фонда

Исключённые признаки:

- ZN — $r = +0.36$ — слабая корреляция, малоинформативен
- DIS — коллинеарен с NOX и INDUS
- RAD — $r = -0.38$ — дублирует информацию TAX

- B — специфичный социальный признак, слабая корреляция
- CHAS — бинарный признак (река рядом?), $r = +0.18$ — почти нет связи

5. Диаграмма рассеяния

Диаграмма рассеяния построена для пары RM (среднее количество комнат) и MEDV (медианная стоимость дома) — признаки с наибольшей корреляцией по модулю. Точки окрашены по категории PRICE_CATEGORY.

```
fig, ax = plt.subplots(figsize=(9, 6))
color_map = {'Low': '#ef4444', 'Medium': '#3b82f6', 'High': '#22c55e'}
marker_map = {'Low': 'o', 'Medium': 's', 'High': '^'}
for cat in ['Low', 'Medium', 'High']:
    mask = df['PRICE_CATEGORY'] == cat
    ax.scatter(df.loc[mask, 'RM'], df.loc[mask, 'MEDV'],
               c=color_map[cat], marker=marker_map[cat],
               alpha=0.65, s=55, label=f'{cat} (n={mask.sum()})')
z = np.polyfit(df['RM'], df['MEDV'], 1)
ax.plot(np.linspace(df.RM.min(), df.RM.max(), 200),
        np.poly1d(z)(np.linspace(df.RM.min(), df.RM.max(), 200)),
        'k--', label=f'Тренд (r={df.RM.corr(df.MEDV):.2f})')
ax.set_xlabel('RM — среднее количество комнат')
ax.set_ylabel('MEDV — медианная стоимость (тыс. $)')
ax.legend()
plt.show()
```




Рис. 4. Диаграмма рассеяния RM vs MEDV с линией тренда.

Вывод: коэффициент корреляции Пирсона $r = 0.6954$ указывает на устойчивую положительную линейную зависимость. Дома категории **High** (зелёные ▲) концентрируются при $RM > 6.5$ и $MEDV > 25$ тыс. \$.